

PROPOSAL RISET TUGAS AKHIR
NATURAL LANGUAGE PROCESSING: PENGEMBANGAN MODEL PART OF SPEECH (POS) TAG
UNTUK PEMROSESAN BAHASA DENGAN SUMBER DAYA TERBATAS (BAHASA SUNDA)

Disusun oleh:

Nama Peserta	: Abi Bayu Perkasa
NIM	: 2305308
Prodi/Jurusan	: Mekatronika dan Kecerdasan Buatan
Semester	: 7 (Tujuh)



MEKATRONIKA DAN KECERDASAN BUATAN
KAMPUS UPI DI PURWAKARTA
UNIVERSITAS PENDIDIKAN INDONESIA
2026

Analisis Komparatif IndoBERT dan mBERT dalam *Cross-Lingual Transfer Learning* untuk *POS Tagging* Bahasa Sunda: Studi Ablasi Kebutuhan Data

Topik	Masalah	Tujuan
Studi Ablasi <i>Data Sufficiency</i> pada <i>Cross-Lingual Transfer Learning</i> Berbasis IndoBERT dan mBERT untuk <i>Part-of-Speech Tagging</i> Bahasa Sunda	1. Bagaimana perbandingan kinerja akurasi dan <i>F1-score</i> antara model representasi lokal IndoBERT dengan model multilingual mBERT dalam melakukan penandaan kelas kata (<i>POS tagging</i>) Bahasa Sunda melalui metode <i>Cross-Lingual Transfer Learning</i> dari Bahasa Indonesia? 2. Berapakah ambang batas minimum volume data latih target (<i>data sufficiency</i>) Bahasa Sunda yang dibutuhkan dalam skenario studi ablasi subset data (100, 500, dan 1.000 kalimat) sebelum performa model mencapai titik <i>error saturation point</i>? 3. Bagaimana karakteristik pola kesalahan sintaksis (<i>error analysis</i>) yang dialami oleh model IndoBERT dan mBERT pada setiap variasi volume <i>dataset</i> target Bahasa Sunda?	1. Membandingkan kinerja akurasi dan <i>F1-score</i> antara model IndoBERT dan mBERT dalam mengeksekusi penandaan kelas kata (<i>POS tagging</i>) bahasa Sunda melalui penerapan metode <i>Cross-Lingual Transfer Learning</i> dari bahasa Indonesia. 2. Menentukan ambang batas minimum volume <i>data sufficiency</i> bahasa Sunda, melalui skenario pengujian studi ablasi subset data (100, 500, dan 1.000 kalimat), guna mengidentifikasi <i>error saturation point</i> pada performa model. 3. Mengevaluasi dan memetakan jenis-jenis kesalahan klasifikasi kelas kata (morfosintaksis) yang paling dominan muncul pada masing-masing model di setiap subset data ablasi guna memberikan rekomendasi perbaikan model
Metode	Kebaruan	Dataset
Penelitian ini menggunakan jenis metode penelitian eksperimental dengan pendekatan <i>Design Science Research Methodology</i> (DSRM) sebagai pendekatan pengembangan sistem prediksi model yang dirancang.	1. Studi Ablasi <i>Data Sufficiency</i> secara bertahap (100, 500, hingga 1.000 kalimat) untuk mengidentifikasi secara kuantitatif <i>error saturation point</i> pada transfer pembelajaran lintas bahasa dari bahasa Indonesia ke bahasa Sunda 2. Membandingkan efisiensi proses belajar (<i>learning curve</i>) antara model IndoBERT dan mBERT melalui metode <i>two-stage fine-tuning</i>. Tujuannya adalah untuk menentukan model mana yang paling efisien ketika dilatih menggunakan data bahasa target yang sangat terbatas. 3. Analisis kesalahan sintaksis dinamis untuk memetakan bagaimana bias "memori sisa" (<i>residual memory</i>) dari bahasa Indonesia sebagai bahasa sumber tereduksi dan bagaimana karakteristik kesalahan morfosintaksis bergeser seiring dengan penambahan data latih bahasa Sunda secara bertahap.	1. Sunda https://dataverse.telkomuniversity.ac.id/dataset.xhtml?persistentId=doi:10.34820/FK2/VTABRH Data ini berisi 3616 baris (kalimat) teks bahasa Sunda yang diambil dari beberapa majalah online berbahasa Sunda (Mangle, Dewan Dakwah Jabar, dan Balebat), dan dianotasi dengan label Part of Speech secara manual oleh beberapa mahasiswa Prodi Pendidikan Bahasa Sunda UPI Bandung. 2. Indonesia https://huggingface.co/datasets/indonlp/indonlu Dataset penandaan bagian ujaran (POS) bahasa Indonesia ini dikumpulkan dari situs web berita Indonesia. Dataset ini terdiri dari sekitar 8.000 kalimat dengan 26 tag POS.
Teori		
Riset ini menggunakan kerangka teori <i>Cross-Lingual Transfer Learning</i> dalam NLP (Natural Language Processing) yang didasarkan pada konsep <i>transfer learning</i> dari Bahasa dengan sumber daya data tinggi ke <i>low-resource language</i>. Pada NLP, efektivitas <i>transfer learning</i> dipengaruhi oleh kedekatan tipologis, struktur penulisan, dan rumpun bahasa (seperti rumpun Austronesia pada bahasa Indonesia, Jawa, dan Sunda), sehingga pemanfaatan model monolingual lokal seperti IndoBERT diperlukan karena kapasitas transfernya terbukti sangat baik dan mampu bersaing dengan model multilingual (mBERT) pada tugas penandaan kelas kata (<i>POS tagging</i>). Konsep studi <i>data sufficiency</i> digunakan sebagai landasan untuk mengidentifikasi ambang batas optimal data latih, yakni titik di mana kinerja model mencapai <i>error saturation point</i>, sehingga proses pelatihan dapat berjalan secara efisien.		

Penelitian Relevan

Penulis dan Tahun	Judul	Temuan Penelitian	Research Gap
(Raj & Kumar, 2026)	How Much Data in Low-Resource Indian Languages Is 'Sufficient' For Transfer Learning: A Comparative Study for POS Annotation	<i>Transfer learning</i> untuk tugas POS tagging pada <i>low-resource language</i> jauh lebih efektif dan efisien dilakukan dengan menyebar dataset berskala kecil (100, 500, 1000) ke berbagai <i>related language</i> dan menggunakan model khusus rumpun bahasa, penggunaan data dalam jumlah besar justru hanya memicu kejenuhan performa (<i>error saturation</i>).	Masalah ketidaksesuaian domain antara data latih tertulis dan data uji lisan, hambatan perbedaan aksara pada <i>cross-language transfer</i> yang memerlukan solusi transliterasi, serta persistensi kesalahan klasifikasi pada beberapa kategori sintaksis akibat keterbatasan arsitektur dan bias model pra-latih.
(Saluja & Dongardive, 2025)	Cross-Lingual Transfer Learning for POS Tagging in Low-Resource Indian Languages: A Hindi-Dogri-Punjabi Case Study	<i>Cross-language transfer learning</i> berbasis arsitektur transformer (mBERT, IndicBERT and XLM-R) untuk bahasa Dogri berhasil melampaui performa model <i>traditional supervised baseline</i> , serta hasil yang optimal dan efisien diraih pada penerapan strategi transfer multi-sumber, metode few-shot, serta penyelarasan aksara melalui transliterasi.	Tingginya kesalahan klasifikasi akibat tumpang tindih morfologis dan variasi dialek bahasa Dogri, sehingga memunculkan kebutuhan akan penelitian lanjutan yang mengintegrasikan analisis morfologi, regularisasi dialek, serta teknik penyesuaian parameter yang efisien.
(Talukdar & Sarma, 2023)	UPOS Tagger for Low Resource Assamese Language: LSTM And BiLSTM Based Modelling	Model neural BiLSTM berbasis Universal POS (UPoS) merupakan arsitektur paling unggul dan efektif untuk tugas POS tagging bahasa Assamese dengan akurasi melampaui 97%, yang sekaligus mampu meminimalkan kebutuhan koreksi manual dari ahli bahasa hingga di bawah 3%.	ketiadaan penanganan kata di luar kosakata (OOV) dan tantangan spesifik domain, belum terintegrasinya fitur morfologi tingkat lanjut untuk mengakomodasi sifat aglutinatif bahasa Assamese, serta kendala klasifikasi pada kategori dengan frekuensi kemunculan yang sangat minim.
(Miani et al., 2026)	Cross-Lingual and Cross-Domain Transfer Learning for Pos Tagging in Historical Germanic Low-Resource Languages	Efektivitas <i>cross-language learning</i> bahasa sangat bergantung pada kesamaan struktural antar-genre (puisi dan prosa), di mana transfer pada domain puisi terbukti sangat berhasil dibandingkan domain	Model sering kesulitan saat menghadapi struktur teks yang berbeda dari data pelatihannya. Hal ini terjadi karena dua alasan, yaitu kurangnya pengujian adaptasi model pasca-transfer, dan ketiadaan model

		prosa yang heterogen, sehingga penggabungan seluruh data <i>cross-language</i> dan genre ke dalam satu model justru menurunkan performa.	<i>POS tagging</i> khusus untuk bahasa sejarah yang minim sumber daya.
(Enrique et al., 2024)	Javanese Part-Of-Speech Tagging Using Cross-Lingual Transfer Learning	metode <i>cross-lingual transfer learning</i> dengan penyesuaian dua tahap dari bahasa Indonesia terbukti paling efektif dalam meningkatkan akurasi <i>POS tagging</i> bahasa Jawa berkat kedekatan rumpun bahasa. Namun, model tersebut masih menyisakan kendala spesifik dalam membedakan kelas kata tertentu dan mengklasifikasikan kosakata asing.	Memerlukan perluasan korpus dataset bahasa Jawa yang saat ini terlalu kecil, kebutuhan eksplorasi analisis fitur linguistik individual guna mengatasi ketidakakuratan prediksi kerangka kerja LangRank, serta tantangan dalam menangani efek memori sisa (<i>residual memory</i>) yang memicu kesalahan pelabelan pada kosakata bahasa sumber.
(Ka et al., 2025)	Improving Low-Resource Kazakh-English and Turkish-English Neural Machine Translation Using Transfer Learning and Part of Speech Tags	Integrasi penandaan kelas kata (POS tagging) dan <i>transfer learning</i> secara bersamaan merupakan pendekatan terbaik untuk menghasilkan terjemahan mesin saraf yang paling fasih, bermakna, dan konsisten secara sintaksis pada pasangan bahasa Kazakh-Inggris dan Turki-Inggris dengan mengoptimalkan kesamaan struktural rumpun bahasa Turkic.	risiko <i>overfitting</i> akibat penambahan fitur POS pada dataset berskala kecil, terbatasnya pemanfaatan fitur linguistik yang belum mencakup lemma dan penganalisis morfologis, serta perlunya eksplorasi penggunaan model induk multilingual dalam proses <i>Cross-Lingual Transfer</i> .
(Mollanorozy et al., 2023)	Cross-Lingual Transfer Learning with Persian Sepideh Mollanorozy	Efektivitas <i>Cross-Lingual Transfer Learning</i> dari bahasa Persia sangat bergantung pada jenis tugas (<i>task-dependent</i>) dan kedekatan linguistik, serta model monolingual ParsBERT menuntut kehadiran bahasa target sejak tahap pre-training pada model multilingual agar proses transfer dapat berhasil.	Kelangkaan dataset analisis sentimen untuk bahasa minim sumber daya yang menghambat evaluasi komparatif lintas tugas secara komprehensif, serta belum terpecahkannya kesenjangan teoretis mengenai mengapa metrik kemiripan bahasa yang efektif pada transfer sintaksis justru tidak konsisten saat diterapkan pada tugas semantik

DAFTAR PUSTAKA

- Enrique, G., Alfina, I., & Yulianti, E. (2024). *Javanese part-of-speech tagging using cross-lingual transfer learning*. 13(3), 3498–3509. <https://doi.org/10.11591/ijai.v13.i3.pp3498-3509>
- Ka, L. G. E., Yazar, A. N., & Kili, B. (2025). *Improving Low-Resource Kazakh-English and Turkish-English Neural Machine Translation Using Transfer Learning and Part of Speech Tags*. January. <https://doi.org/10.1109/ACCESS.2025.3542491>
- Miani, I., Stymne, S., & Darwin, G. (2026). *Cross-Lingual and Cross-Domain Transfer Learning for POS Tagging in Historical Germanic Low-Resource Languages*. *LoResLM*, 542–558.
- Mollanorozy, S., Tanti, M., & Nissim, M. (2023). *Cross-lingual Transfer Learning with Persian*. *Sigtyp*, 89–95.
- Raj, M., & Kumar, R. (2026). *How Much Data in Low-resource Indian Languages is " Sufficient " for Transfer Learning : A Comparative Study for POS Annotation*. 25(1), 1–26.
- Saluja, V., & Dongardive, J. (2025). *Cross-Lingual Transfer Learning for POS Tagging in Low-Resource Indian Languages: A Hindi–Dogri–Punjabi Case Study*. *IEEE, 2025 7th I*, 1–6. <https://doi.org/10.1109/AIST68591.2025.11441610>.
- Talukdar, K., & Sarma, S. K. (2023). *UPoS Tagger for Low Resource Assamese Language : LSTM and BiLSTM based Modelling*. *2023 IEEE International Conference on Machine Learning and Applied Network Technologies (ICMLANT)*, 1–6. <https://doi.org/10.1109/ICMLANT59547.2023.10372865>